MINI-PROJET 03

Prédiction des besoins énergétiques des bâtiments

1 Contexte et problématique

Les besoins de chauffage des bâtiments dépendent notamment de leur géométrie, de leur orientation et de leurs vitrages. À partir de 768 configurations simulées, construire et comparer des modèles capables d'estimer la charge de chauffage. L'objectif est de confronter les approches linéaires et non linéaires.

Question centrale : Quel modèle prédit le plus précisément la charge de chauffage et quelles caractéristiques influencent les erreurs ?

2 Jeu de données public

Source	Energy Efficiency — UCI Machine Learning Repository
Description	768 observations simulées · 8 caractéristiques · 2 cibles possibles
Variable cible	Charge de chauffage (Y1) ; Y2 (refroidissement) réservé à l'extension

Accès et téléchargement : fiche officielle UCI | https://archive.ics.uci.edu/dataset/242/energy+efficiency

3 Algorithmes à comparer (Liste non exhaustive)

Méthode de Machine Learning	Hyperparamètre(s) à étudier
Régression linéaire	modèle de référence (sans réglage)
Régression Ridge	alpha
KNN Regressor	nombre de voisins k, distance
Arbre de régression	profondeur maximale
Random Forest Regressor	nombre d'arbres, profondeur

4 Évaluation des performances

MAE, MSE, RMSE et coefficient de détermination R^2. Comparer les erreurs sur le jeu de test et analyser la distribution des résidus.

5 Protocole expérimental obligatoire

1. Importer la base ; étudier les huit caractéristiques X1 à X8 et la distribution de la cible Y1 ; vérifier les données manquantes.
2. Séparation aléatoire 80 % apprentissage / 20 % test, avec graine aléatoire fixée.
3. Utiliser Y1 comme seule cible ; exclure Y2 des entrées. Justifier le traitement des variables et standardiser si nécessaire.
4. Comparer les cinq régressions ; ajuster au moins un hyperparamètre pour quatre modèles par validation croisée sur le train.
5. Calculer les métriques une seule fois sur le test et présenter un tableau comparatif complet.
6. Analyser les résidus, les écarts entre modèles linéaires et non linéaires et les limites d'un jeu de données simulé.

6 Visualisations minimales

- Distribution de Y1 et relations entre Y1 et plusieurs caractéristiques.
- Nuage de points valeurs observées / prédites pour deux modèles.
- Comparaison des RMSE et R^2 ; graphique des résidus du meilleur modèle.

7 Livrables attendus

Notebook Jupyter / Python	Code exécutable, documenté et reproductible, avec graphiques et résultats.
Rapport (3 à 5 pages)	Contexte, préparation, méthodologie, résultats, discussion et conclusion.
Présentation (8 à 10 min)	Synthèse des choix, comparaison des modèles et recommandations.