ROYAUME DU MAROC
HAUT-COMMISSARIAT AU PLAN
INSTITUT NATIONAL DE STATISTIQUE
ET D'ÉCONOMIE APPLIQUÉE

INSEA

Rapport de mini-projet de Machine Learning

Mini-projet 03

Sujet

Prédiction des besoins énergétiques des bâtiments

Comparaison de cinq modèles pour la charge de chauffage

Réalisé par

ELKIHEL ELMEHDI
EL ASSRI L'HOUCINE
SAID CHARAF

Année universitaire 2026–2027

1 Contexte et données

La charge de chauffage d'un bâtiment dépend de sa géométrie et de ses vitrages. Ce mini-projet compare cinq méthodes de régression afin de prédire cette charge à partir du jeu public *Energy Efficiency* de l'UCI. L'objectif est double : comparer les approches linéaires et non linéaires et examiner les cas où le modèle commet les plus fortes erreurs. Il s'agit d'une étude de configurations *simulées*, et non d'une validation sur des bâtiments réels.

Le fichier contient 768 lignes sans valeur manquante. Les huit entrées sont X_1 (compacité relative), X_2 (surface), X_3 (surface des murs), X_4 (surface du toit), X_5 (hauteur), X_6 (orientation), X_7 (surface vitrée) et X_8 (distribution des vitrages). La cible unique est Y_1, charge de chauffage. La seconde sortie Y_2, charge de refroidissement, est exclue des entrées et des modèles. L'orientation et la distribution des vitrages sont encodées comme des catégories, pour ne pas imposer un ordre numérique artificiel.

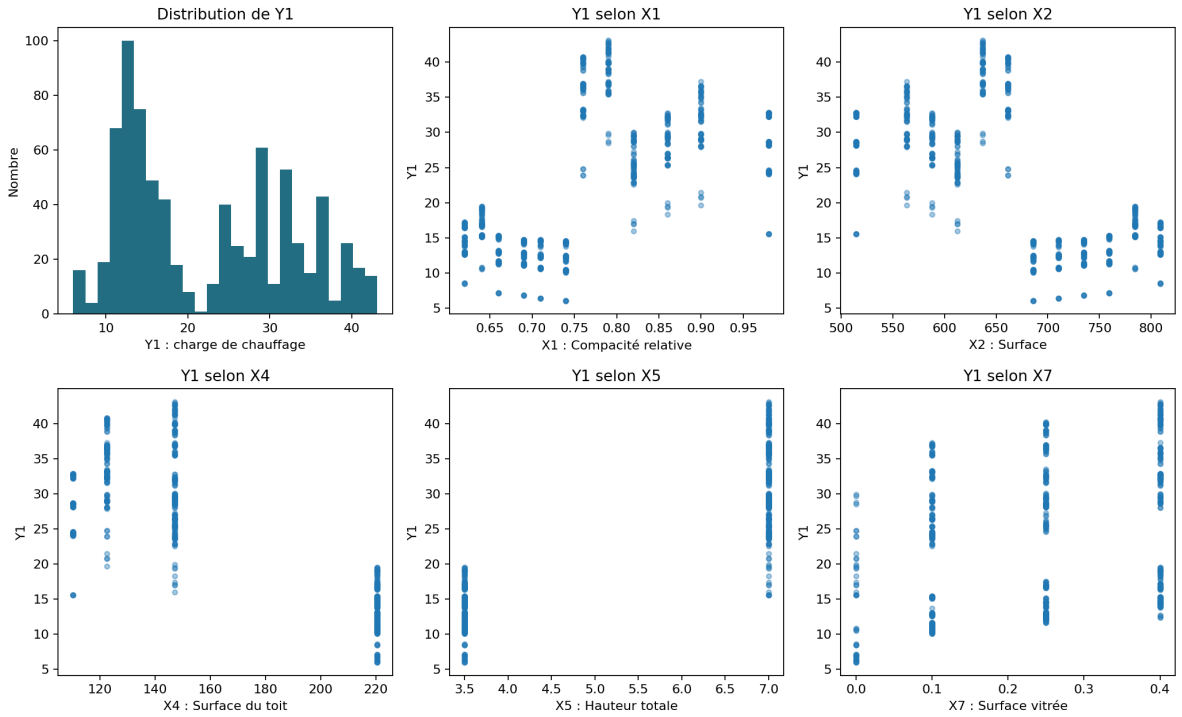


Figure 1: Distribution de Y_1 et relations descriptives avec cinq caractéristiques. Les observations sont simulées.

La distribution de Y_1 est étalée et les relations avec les caractéristiques ne semblent pas toutes linéaires. Les graphiques sont descriptifs ; ils ne suffisent pas à établir un effet causal d'une variable sur la consommation.

2 Protocole expérimental

Nous utilisons une séparation aléatoire fixée par `random_state=42` : 614 observations (80 %) pour l'entraînement et 154 (20 %) pour le test. Sur l'entraînement uniquement, une validation croisée à cinq plis, mélangés avec la même graine, compare les réglages selon le RMSE moyen. Le test est réservé au calcul final des métriques.

La régression linéaire constitue la référence sans hyperparamètre réglé. Ridge ajoute une pénalisation L_2 dont le coefficient α est choisi par validation. KNN compare plusieurs nombres de voisins, distances et pondérations. L'arbre de décision compare profondeur et taille minimale des feuilles. Random Forest compare le nombre d'arbres, leur profondeur et la taille minimale des feuilles. Les grilles exactes et les paramètres retenus sont conservés dans le code et dans `results/parameters.json`.

Les six variables quantitatives sont standardisées pour les modèles sensibles à l'échelle (linéaire, Ridge et KNN). La standardisation n'est pas nécessaire pour les modèles arborescents. Chaque transformation est dans le pipeline : pendant un pli, elle est ajustée sur la seule sous-partie d'apprentissage. Cela évite de transmettre à l'entraînement des informations provenant de la validation ou du test.

Pour une vraie valeur y_i et sa prédiction $\hat{y}_i$, nous calculons :

$$\mathrm{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|, \qquad \mathrm{MSE} = \frac{1}{n}\sum_i (y_i - \hat{y}_i)^2, \qquad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}.$$

Le coefficient $R^2 = 1 - \sum_i (y_i - \hat{y}_i)^2 / \sum_i (y_i - \bar{y})^2$ compare l'erreur du modèle à celle d'une prédiction constante égale à la moyenne du test. Les trois mesures d'erreur sont meilleures lorsqu'elles diminuent ; R^2 est meilleur lorsqu'il se rapproche de 1.

3 Résultats sur les 154 observations de test

Modèle	RMSE CV	MAE	MSE	RMSE	R^2
Régression linéaire	2,828	2,059	8,250	2,872	0,921
Ridge	2,828	2,061	8,257	2,874	0,921
KNN	1,559	1,118	2,793	1,671	0,973
Arbre de décision	0,579	0,353	0,282	**0,531**	**0,997**
Random Forest	**0,535**	0,371	0,287	0,536	0,997

Table 1: Comparaison des cinq modèles. RMSE CV : moyenne de validation croisée sur l'entraînement ; autres colonnes : test. Valeurs arrondies.

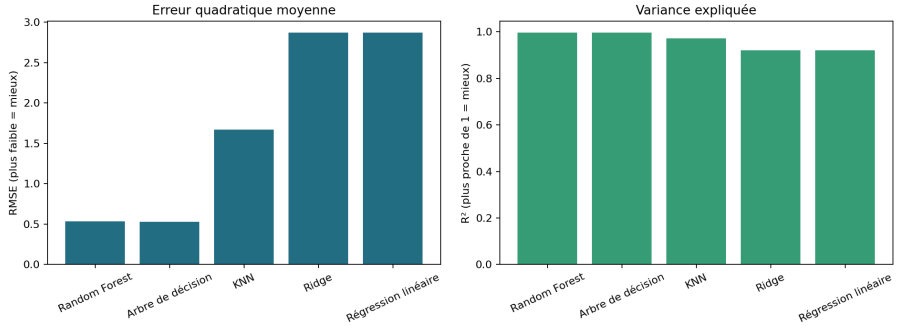


Figure 2: Comparaison visuelle du RMSE et du R^2 sur le test.

Random Forest présente le plus faible RMSE de validation croisée et constitue donc le modèle sélectionné avant l'examen du test. L'arbre obtient un RMSE de test légèrement plus faible (0,531 contre 0,536) sur cette partition précise. Cette faible différence ne démontre pas une supériorité générale.

4 Prédictions, erreurs et discussion

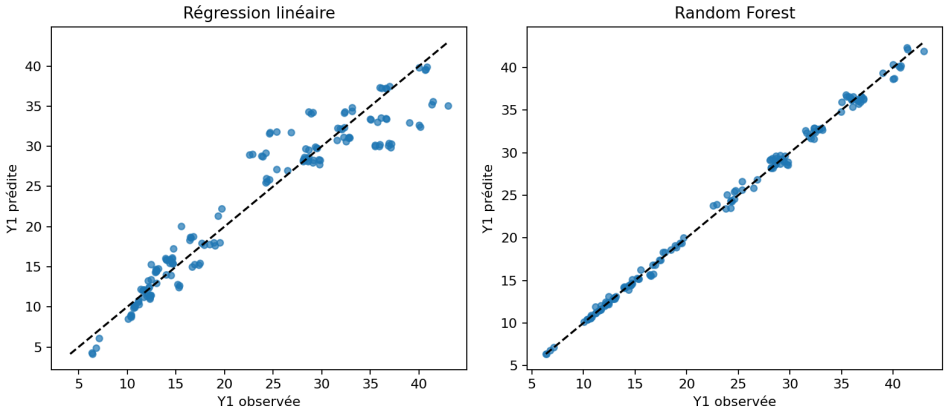


Figure 3: Valeurs observées et prédites sur le test, pour la référence linéaire et Random Forest. La diagonale correspond à une prédiction parfaite.

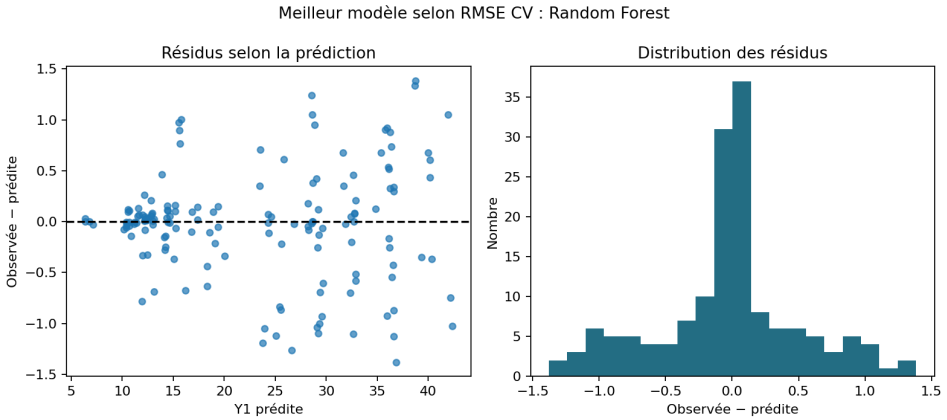


Figure 4: Résidus de Random Forest sur le test : valeur observée moins valeur prédite.

Les approches non linéaires obtiennent ici des erreurs nettement plus faibles que les modèles linéaires. Les résidus de Random Forest restent globalement proches de zéro mais comportent des écarts. Le fichier `results/erreurs_par_groupe.csv` décrit aussi les erreurs absolues selon la hauteur (X_5), l'orientation (X_6) et les vitrages (X_7, X_8). Par exemple, la MAE observée est de 0,171 pour $X_5 = 3{,}5$ (72 cas), contre 0,546 pour $X_5 = 7$ (82 cas). Ces écarts sont descriptifs : les sous-groupes diffèrent possiblement sur d'autres variables et leurs tailles sont limitées. Ils ne permettent donc pas d'attribuer l'erreur à la seule hauteur.

Limites et conclusion. Les données représentent 768 configurations simulées et le test une seule partition de 154 cas. Les résultats ne démontrent pas une performance identique sur des bâtiments réels. Une validation externe et une étude plus complète des erreurs seraient nécessaires avant tout usage pratique. Dans le cadre de ce protocole, Random Forest est le meilleur choix selon la validation croisée ; l'arbre et la forêt ont des performances finales très proches.

Source des données : UCI Machine Learning Repository, *Energy Efficiency*, dataset 242. `https://archive.ics.uci.edu/dataset/242/energy+efficiency`.