Script oral — mini-projet 03

El Assri L’Houcine
Diapositives 4 et 5 · environ 2 min 05

Diapositive 4 — Protocole

Pour comparer les modèles correctement, nous avons séparé les données en deux groupes : 614 configurations pour l’entraînement et 154 pour le test. La graine aléatoire fixée à 42 rend cette séparation reproductible. Le test est gardé à part jusqu’à l’évaluation finale. Sur les données d’entraînement, nous utilisons une validation croisée à cinq plis. En pratique, le modèle apprend cinq fois sur des sous-ensembles différents et nous comparons les réglages selon leur RMSE moyen. Le RMSE mesure l’écart entre les charges prédites et observées : plus il est faible, mieux c’est. Les transformations des variables sont réalisées dans les pipelines, à l’intérieur de chaque pli, pour éviter de transmettre des informations de validation au modèle.

Diapositive 5 — Les cinq méthodes

Nous comparons cinq méthodes. La régression linéaire sert de référence : elle cherche une relation linéaire entre les caractéristiques et Y1. Ridge suit la même idée, en limitant les coefficients trop grands grâce à une pénalisation. KNN prévoit la charge à partir de configurations voisines ; ici, le réglage retenu utilise cinq voisins. L’arbre de décision pose des questions successives sur les caractéristiques. Enfin, Random Forest combine de nombreux arbres ; notre réglage en contient deux cents. Ridge, KNN, l’arbre et la forêt ont chacun des paramètres choisis par validation croisée. Les variables numériques sont standardisées pour les méthodes sensibles aux échelles ; l’orientation et la répartition des vitrages sont traitées comme des catégories. Said va maintenant montrer les résultats et les erreurs.

Conseil : parle naturellement, en montrant le graphique ou la diapositive concernée. Les durées sont indicatives ; répétez ensemble pour rester sous six minutes.