Script oral — mini-projet 03

El Assri L’Houcine

Diapositives 4 et 5 · environ 1 min 30

Diapositive 4 — Protocole

Nous avons séparé les 768 configurations en deux groupes : 614 pour entraîner les modèles et 154 pour les tester à la fin. Les 154 cas du test restent à part pendant l’apprentissage. Sur les 614 autres, nous utilisons une validation croisée à cinq plis : le modèle apprend sur quatre parties et nous vérifions ses prédictions sur la cinquième. Nous répétons cela cinq fois pour choisir les réglages. Nous retenons ceux qui donnent le plus petit RMSE, c’est-à-dire les plus petites erreurs de prédiction. Les données sont préparées à l’intérieur de chaque étape pour éviter que le modèle voie les réponses du contrôle.

Diapositive 5 — Cinq modèles

Nous comparons cinq méthodes. La régression linéaire sert de référence ; Ridge lui ajoute un frein pour limiter des coefficients trop grands. KNN cherche les bâtiments les plus ressemblants : notre réglage utilise cinq voisins. L’arbre de décision classe en posant des questions successives sur les caractéristiques. Random Forest combine les prédictions de deux cents arbres. Les réglages des quatre derniers modèles ont été choisis sur les données d’entraînement. Said va maintenant présenter leurs résultats et leurs erreurs.

Conseil : parle naturellement, en montrant le graphique ou la diapositive concernée. Les durées sont indicatives ; répétez ensemble pour rester sous six minutes.